

Modelagem ARIMA/SARIMA da série mensal de volume de vendas da PMC

Leonardo Yves
DRE 120041695

Análise de Séries Temporais - MAD485
Professor João Batista M. Pereira
Período 2026.1

Resumo

Este relatório analisa a série mensal do índice de volume de vendas da Pesquisa Mensal de Comércio, com o objetivo de ajustar modelos ARIMA/SARIMA e produzir previsões de curto prazo com incerteza associada. A seleção do modelo combina critérios de informação, diagnóstico residual e desempenho preditivo em uma janela de teste observada. O modelo selecionado foi um SARIMA(1,1,3)(0,1,1)₁₂, que apresentou MAPE de 1,35% no período de teste de 24 meses. Os resíduos, entretanto, ainda apresentam autocorrelação pelo teste de Ljung–Box, o que é tratado como limitação do ajuste.

1 Introdução

O objetivo deste trabalho é analisar uma série temporal mensal e ajustar modelos ARIMA ou SARIMA adequados, conforme solicitado no enunciado do Trabalho Aplicado 1 da disciplina Análise de Séries Temporais. A série escolhida foi o índice de volume de vendas da Pesquisa Mensal de Comércio, aqui representado pela variável `pmc_volume_index`.

A análise segue um fluxo de Box–Jenkins: descrição da série, investigação de estacionariedade, ajuste de modelos concorrentes, avaliação por critérios de informação, diagnóstico de resíduos e previsão. Para que a avaliação preditiva seja observável, os últimos 24 meses da amostra foram reservados como conjunto de teste. Assim, as previsões produzidas pelos modelos concorrentes puderam ser comparadas com valores efetivamente observados.

O foco do trabalho é univariado. Embora a base bruta contenha também uma coluna de SELIC, essa variável foi preservada apenas como contexto e não entrou no modelo principal. Essa decisão mantém o trabalho aderente ao objetivo central do enunciado: identificar, ajustar e diagnosticar modelos ARIMA/SARIMA para uma série temporal.

O código, as bases utilizadas e os artefatos reproduzíveis do trabalho estão disponíveis em https://github.com/lyvesmatufrj/trabalho_aplicado1_ast.

2 Descrição dos dados

A base utilizada contém 315 observações mensais, de janeiro de 2000 a março de 2026. A série modelada é o índice de volume de vendas da Pesquisa Mensal de Comércio (PMC), pesquisa divulgada pelo Instituto Brasileiro de Geografia e Estatística (IBGE), denotado no projeto por `pmc_volume_index`. A escala temporal é mensal, com datas registradas no primeiro dia de cada mês.

O arquivo consolidado utilizado como entrada do projeto é `data/raw/dataset_pmc_selic_monthly.csv`. Para a modelagem univariada foi gerada uma base tratada em `data/processed/pmc_monthly_model_input.csv`, contendo apenas as colunas `date` e `pmc_volume_index`. Não foram identificadas lacunas mensais nem valores ausentes na série principal.

Tabela 1: Estatísticas descritivas da série PMC

Estatística	Valor
Número de observações	315
Média	81,78
Desvio-padrão	22,29
Mínimo	43,32
Primeiro quartil	60,04
Mediana	88,92
Terceiro quartil	97,52
Máximo	131,81
Assimetria	-0,18
Curtose	-0,97

3 Análise exploratória

A Figura 1 apresenta a série em nível. Observa-se crescimento de longo prazo até meados da década de 2010, queda acentuada em períodos de choque econômico e recuperação posterior. A série também apresenta padrão sazonal, esperado em uma série mensal de comércio.




Figura 1: Série mensal do índice de volume de vendas da PMC

A decomposição STL, apresentada na Figura 2, reforça a presença de componente sazonal mensal e de variações de tendência ao longo da amostra. Esse comportamento justifica considerar modelos SARIMA com período sazonal igual a 12.




Figura 2: Decomposição STL da série

A análise de ACF e PACF em nível indica dependência serial persistente, consistente com não estacionariedade em nível e com a necessidade de diferenciação regular e sazonal. Os testes formais também apontaram nessa direção: em nível, o teste ADF não rejeitou raiz unitária, enquanto o KPSS rejeitou estacionariedade. A série com diferença regular e diferença sazonal apresentou evidências mais favoráveis à estacionariedade.




Figura 3: ACF e PACF da série em nível

4 Identificação, ajuste e comparação de modelos

Foram ajustados modelos ARIMA e SARIMA com diferenciação regular $d = 1$ e, para os modelos sazonais, diferenciação sazonal $D = 1$ com período $s = 12$. A forma geral considerada para os modelos sazonais pode ser escrita como

$$\Phi(B^{12})\phi(B)(1 - B)^d(1 - B^{12})^D y_t = \Theta(B^{12})\theta(B)\varepsilon_t,$$

em que B é o operador de defasagem, $\phi(B)$ e $\theta(B)$ representam os polinômios autorregressivo e de média móvel, $\Phi(B^{12})$ e $\Theta(B^{12})$ representam os componentes sazonais, e ε_t é o erro do modelo.

Para avaliar risco preditivo, a amostra foi dividida em treino e teste. O treino cobre janeiro de 2000 a março de 2024, com 291 observações. O teste cobre abril de 2024 a março de 2026, com 24 observações. Os modelos foram ajustados apenas no treino e comparados por previsões para o período de teste.

Tabela 2: Modelos concorrentes com melhor desempenho preditivo

Modelo	AIC treino	BIC treino	RMSE teste	MAPE teste
SARIMA(1,1,3)(0,1,1) ₁₂	1238,25	1259,66	1,78	1,35%
SARIMA(3,1,1)(0,1,1) ₁₂	1245,61	1267,07	1,79	1,36%
SARIMA(2,1,1)(0,1,1) ₁₂	1243,62	1261,50	1,79	1,36%
SARIMA(1,1,1)(1,1,1) ₁₂	1243,62	1261,50	1,79	1,36%
SARIMA(1,1,1)(0,1,1) ₁₂	1241,63	1255,93	1,79	1,36%

O modelo com menor RMSE no teste foi o SARIMA(1,1,3)(0,1,1)₁₂. O desempenho dos cinco melhores modelos foi muito próximo, mas a escolha pelo menor erro preditivo é coerente com o objetivo de previsão do trabalho. O AIC/BIC foi usado como critério auxiliar, não como critério exclusivo.

5 Diagnóstico do modelo selecionado

O modelo SARIMA(1,1,3)(0,1,1)₁₂ foi reestimado na amostra completa após a seleção com base no teste. O diagnóstico residual avaliou centralização dos resíduos, autocorrelação residual, distribuição aproximada e comportamento temporal dos erros.

O modelo assume que, após uma diferenciação regular e uma diferenciação sazonal de período 12, a série se torna aproximadamente estacionária. Na escala diferenciada, a dependência temporal é representada pelos componentes autorregressivos e de médias móveis especificados, com erros de média zero, variância aproximadamente constante e ausência de autocorrelação serial. A especificação é univariada, não inclui variáveis exógenas nem tendência determinística explícita. Essas suposições são avaliadas por meio do diagnóstico dos resíduos.




Figura 4: Diagnóstico dos resíduos do modelo selecionado

O ponto crítico do ajuste está no teste de Ljung–Box. Os p-valores foram baixos nas defasagens 6, 12, 18 e 24, indicando rejeição da hipótese de ausência de autocorrelação residual. A Tabela 3 resume os resultados.

Tabela 3: Teste de Ljung–Box para os resíduos

Defasagem	Estatística	p-valor
6	23,36	0,0007
12	77,82	$1,07 \times 10^{-11}$
18	79,97	$8,68 \times 10^{-10}$
24	80,92	$4,34 \times 10^{-8}$

Portanto, o modelo selecionado apresenta bom desempenho preditivo no teste, mas não elimina completamente a dependência serial dos resíduos. Essa limitação sugere que a série pode conter choques, quebras estruturais ou componentes não capturados por um SARIMA simples. Como o enunciado solicita um relatório curto e focado em ARIMA/SARIMA, essa evidência foi registrada como limitação, em vez de expandir o trabalho para modelos mais complexos.

6 Previsão

Antes da previsão futura, o modelo foi avaliado em uma janela de teste dentro da amostra observada. No período de abril de 2024 a março de 2026, o SARIMA(1,1,3)(0,1,1)₁₂ apresentou MAE de 1,45, RMSE de 1,78 e MAPE de 1,35%. O erro absoluto máximo foi 3,45 pontos do índice. A Figura 5 compara a previsão retrospectiva com os valores observados no teste.




Figura 5: Previsão avaliável no período de teste

Em seguida, o modelo foi reestimado na amostra completa e usado para prever 12 meses à frente, de abril de 2026 a março de 2027. A Figura 6 apresenta a previsão pontual e o intervalo de 95%.




Figura 6: Previsão futura de 12 meses com intervalo de 95%

Tabela 4: Previsões futuras do modelo selecionado

Mês	Previsão	Limite inferior	Limite superior
2026-04	105,59	100,75	110,42
2026-05	110,51	104,76	116,26
2026-06	105,58	99,28	111,88
2026-07	109,88	103,20	116,56
2026-08	110,27	103,29	117,25
2026-09	106,15	98,90	113,40
2026-10	111,31	103,81	118,80
2026-11	118,34	110,61	126,07
2026-12	132,42	124,47	140,38
2027-01	107,49	99,31	115,66
2027-02	101,09	92,71	109,48
2027-03	110,49	101,90	119,08

Como esperado, os intervalos de previsão se tornam mais amplos conforme o horizonte aumenta. A previsão preserva o padrão sazonal da série, com valores mais elevados no fim do ano.

7 Conclusão

O trabalho ajustou modelos ARIMA/SARIMA para a série mensal do índice de volume de vendas da PMC. A análise exploratória indicou tendência, sazonalidade e forte dependência serial em nível. Por isso, foram considerados modelos com diferenciação regular e, no caso dos modelos sazonais, diferenciação sazonal de período 12.

A seleção do modelo foi feita com uma janela de teste observada, o que permitiu mensurar o risco preditivo. O modelo escolhido foi o SARIMA(1,1,3)(0,1,1)₁₂, com MAPE de 1,35% no teste de 24 meses. Esse desempenho sugere boa capacidade de previsão de curto prazo para a série analisada.

A principal limitação é o diagnóstico residual: o teste de Ljung–Box indicou autocorrelação remanescente. Assim, o modelo deve ser interpretado como um baseline SARIMA com bom desempenho preditivo, mas não como uma especificação final perfeita do processo gerador da série. Extensões naturais envolveriam investigar quebras estruturais, choques econômicos ou modelos com componentes adicionais.

7.1 Disponibilização do código

O código utilizado está disponível no repositório:

https://github.com/lyvesmatufrj/trabalho_aplicado1_ast

O notebook principal está em:

```
notebooks/  
01_trabalho1_ast_pmc_arima_sarima.ipynb
```

O pipeline reprodutível por script está em:

```
src/run_trabalho1_pipeline.py
```

As bases utilizadas para reprodução estão em **data/**. As figuras e tabelas intermediárias foram geradas automaticamente em **reports/**.